

پیشنهاد دیتاست اصلی پروژه – نسخه‌ی دوم (مقیاس بزرگ)

پروژه: ساخت گراف دانش از متن غیرساختاریافته دیتاست پیشنهادی: DocRED (پیکره‌ی کامل) – بخش

برچسب‌خورده‌ی انسانی به‌همراه بخش نظارت‌ازدور زبان: انگلیسی · لایسنس: MIT منبع رسمی:

Parquet: <https://huggingface.co/datasets/thunlp/docred> · نسخه‌ی <https://github.com/thunlp/DocRED>

مقاله‌ی مرجع: Yao et al., *DocRED: A Large-Scale Document-Level Relation Extraction Dataset*, ACL

dev/test: Tan et al., *Revisiting* بازبینی‌شده‌ی برچسب‌های /2019 – <https://aclanthology.org/P19-1074>

DocRED – Addressing the False Negative Problem, EMNLP 2022

۱. چه چیزی نسبت به پیشنهاد قبلی عوض شد

پیشنهاد قبلی ما Re-DocRED بود که ۴,۰۵۳ سند برچسب‌خورده دارد، و بازخوردی که گرفتیم این بود که برای این پروژه کوچک است. در این نسخه کل پیکره‌ی DocRED را برمی‌داریم: همان ۴,۰۵۳ سند، به‌اضافه‌ی ۱,۰۰۰ سند test و ۱۰۱,۸۷۳ سند نظارت‌ازدور که با هم‌ترازی Wikidata برچسب خورده‌اند.

شاخص	پیشنهاد قبلی (Re-DocRED)	پیشنهاد فعلی (DocRED کامل)	نسبت
تعداد سند	۴,۰۵۳	۱۰۶,۹۲۴	۲۶ برابر
تعداد واژه	۸۰۴,۱۷۲	۲۱,۳۳۰,۱۹۰	۲۷ برابر
تعداد موجودیت	۷۸,۸۲۲	۲,۰۶۴,۰۴۴	۲۶ برابر
تعداد ذکر (mention)	۱۰۵,۶۸۸	۲,۶۹۰,۶۷۶	۲۵ برابر
تعداد سه‌تایی برچسب‌خورده	۱۲۰,۶۶۴	۱,۵۵۶,۰۹۳	۱۳ برابر
جفت‌موجودیت نامزد	۱/۵۸ میلیون	۴۱/۱ میلیون	۲۶ برابر
حجم خام	۲۴ مگابایت	۳۸۰ مگابایت (JSONL)	۱۶ برابر

تمام اعداد این سند را با `python -m src.docred stats` از روی خود فایل‌ها شمرده‌ایم و خروجی در `data/benchmark/docred/stats.json` و `stats_detail.json` ذخیره است، پس هیچ‌کدام نقل‌قول از مقاله نیست.

۲. جدول ۱ – ابعاد هر بخش

بخش	نوع برچسب	سند	جمله	واژه	موجودیت	ذکر	سه تایی
train_annotated	انسانی	۳,۰۵۳	۲۴,۲۵۶	۶۰۳,۴۶۸	۵۹,۴۹۳	۷۹,۴۸۱	۳۸,۱۸۰
validation (dev)	انسانی	۹۹۸	۸,۰۵۷	۲۰۰,۰۷۷	۱۹,۵۲۸	۲۶,۱۴۱	۱۲,۲۷۵
test	مخفی (لیدربرد)	۱,۰۰۰	—	۱۹۷,۷۸۷	۱۹,۵۳۹	۲۶,۷۰۴	—
train_distant	نظارت‌ازدور (Wikidata)	۱۰۱,۸۷۳	۸۲۸,۱۱۵	۲۰,۳۲۸,۸۵۸	۱,۹۶۵,۴۸۴	۲,۵۵۸,۳۵۰	۱,۵۰۵,۶۳۸
جمع		۱۰۶,۹۲۴		۲۱,۳۳۰,۱۹۰	۲,۰۶۴,۰۴۴	۲,۶۹۰,۶۷۶	۱,۵۵۶,۰۹۳

برچسب‌های بازبینی‌شده‌ی Re-DocRED، یعنی ۱۲۰,۶۶۴ سه‌تایی روی ۴,۰۵۳ سند، را هم کنار این پیکره نگه می‌داریم. دو دلیل دارد: برای dev و test کامل‌تر و دقیق‌ترند، و اجازه می‌دهند نتیجه با کارهای منتشرشده‌ی ۲۰۲۲ به بعد مقایسه شود.

شاخص	مقدار
تعداد نوع رابطه	۹۶ (خصیصه‌های Wikidata)
تعداد نوع موجودیت	۶ (PER, ORG, LOC, TIME, NUM, MISC)
میانگین واژه در هر سند	۱۹۹/۵
میانگین موجودیت در هر سند	۱۹/۳
میانگین سه‌تایی در هر سند (بخش نظارت‌ازدور)	۱۴/۸

۳. جدول ۲ – توزیع نوع موجودیت (کل پیکره)

نوع	معنی	تعداد	سهم
LOC	مکان	۶۲۳,۳۴۶	۳۰/۵٪
PER	شخص	۳۹۹,۲۵۴	۱۹/۵٪
TIME	زمان	۳۵۱,۹۹۳	۱۷/۲٪
MISC	سایر	۳۱۲,۳۵۳	۱۵/۳٪
ORG	سازمان	۲۸۰,۴۳۲	۱۳/۷٪
NUM	عدد	۷۷,۱۲۷	۳/۸٪

(بدون بخش test که برچسب رابطه ندارد ولی موجودیت‌هایش شمرده شده است.)

۴. جدول ۳ – ده رابطه‌ی پرتکرار در بخش نظارت‌ازدور

رتبه	رابطه (نام Wikidata)	تعداد
۱	country	۳۱۳,۹۶۱
۲	located in the administrative territorial entity	۱۴۳,۰۰۶
۳	country of citizenship	۱۲۶,۳۶۰
۴	contains administrative territorial entity	۶۲,۶۴۶
۵	publication date	۳۷,۵۳۸
۶	country of origin	۳۶,۰۲۹
۷	capital	۳۴,۰۴۷
۸	date of birth	۳۳,۹۹۸
۹	place of birth	۳۱,۲۳۲
۱۰	capital of	۲۹,۸۱۶

هر ۹۶ رابطه در هر سه بخش برچسب‌خورده حضور دارند.

۵. جدول ۴ – ویژگی‌های هر رکورد (Schema)

فیلد	سطح	نوع	توضیح
title	سند	متن	عنوان مقاله‌ی ویکی‌پدیا
sents	سند	آرایه‌ی آرایه	جمله‌های سند، توکن‌شده
vertexSet	سند	آرایه	فهرست موجودیت‌ها؛ هر موجودیت فهرستی از ذکرها
vertexSet[i][j].name	ذکر	متن	شکل ظاهری در متن
vertexSet[i][j].type	ذکر	برچسب	یکی از ۶ نوع
vertexSet[i][j].sent_id	ذکر	عدد	شماره‌ی جمله
vertexSet[i][j].pos	ذکر	بازه	موقعیت توکنی
labels.head / labels.tail	رابطه	اندیس	موجودیت مبدأ و مقصد
labels.relation_id / relation_text	رابطه	برچسب	شناسه و نام خصیصه‌ی Wikidata
labels.evidence	رابطه	آرایه	شماره‌ی جمله‌های شاهد (فقط بخش انسانی)

۶. چرا این پیکره بزرگ و چالشی است

۶.۱ مقیاس واقعی. با ۱۰۷ هزار سند و ۲۱ میلیون واژه، هیچ مرحله‌ای از خط لوله دیگر نمی‌تواند تکنخی یا بدون قابلیت ازسرگیری باشد. برای همین استخراج‌کننده را هم‌زمان کردیم (۴۸ درخواست موازی)، کش در سطح سند گذاشتیم و بارگذاری Neo4j را دسته‌ای کردیم.

۶.۲ استدلال چندجمله‌ای. در بخش انسانی ۴۵/۵٪ و در بخش نظارت‌ازدور ۵۷/۶٪ سه‌تایی‌ها (۸۶۷,۶۳۴ مورد) بین دو موجودیتی است که در هیچ جمله‌ای با هم ظاهر نمی‌شوند.

۶.۳ نامتوازن شدید. از ۴۱/۱ میلیون جفت نامزد فقط ۳/۸٪ رابطه دارند. مدل باید بیش از ۹۶٪ جفت‌ها را درست رد کند.

۶.۴ چندبرچسبی. ۱۵۱,۶۷۹ جفت موجودیت بیش از یک رابطه‌ی هم‌زمان دارند.

۶.۵ حل موجودیت در مقیاس میلیونی. ۲/۶۹ میلیون ذکر به ۲/۰۶ میلیون موجودیت نگاشت می‌شود و یک موجودیت واحد در ده‌ها هزار سند تکرار می‌شود؛ مثلاً «Iran» در بخش نظارت‌ازدور هزاران بار می‌آید. ادغام بین‌سندی را در دیتاست شهرداری با یک کلید یکتا حل کرده بودیم، ولی اینجا همان کار باید روی میلیون‌ها گره جواب بدهد.

۶.۶ دو نوع برچسب، دو نوع ارزیابی. بخش انسانی معیار F1 و Ign F1 استاندارد می‌دهد و با نتایج ACL/EMNLP قابل مقایسه است. بخش نظارت‌ازدور برچسب نویزی دارد (اصل مقاله‌ی DocRED هم این را می‌گوید)، پس روی آن

«میزان توافق با برچسب ازدور» گزارش می‌شود نه F1، و بخشی از اختلاف‌ها با نمونه‌گیری بررسی می‌شود.

۶.۷ هزینه‌ی محاسباتی قابل اندازه‌گیری. هر سند حدود ۲,۳۰۰ توکن ورودی و خروجی مدل زبانی می‌برد، پس اجرای کامل روی ۱۰۷ هزار سند چیزی حدود ۲۵۰ میلیون توکن می‌شود. در گزارش نهایی همین تخمین را کنار هزینه‌ی واقعی گذاشته‌ایم تا معلوم شود چقدر درست بوده.

۷. مقایسه با دیتاست شهرداری (مطالعه‌ی موردی فصل آخر)

شاخص	شهرداری	DocRED کامل	نسبت
تعداد سند	۷	۱۰۶,۹۲۴	۱۵,۲۷۵ برابر
تعداد واژه	۸۱۱	۲۱,۳۳۰,۱۹۰	۲۶,۳۰۰ برابر
تعداد موجودیت	۳۸	۲,۰۶۴,۰۴۴	۵۴,۳۰۰ برابر
تعداد سه‌تایی	۳۹	۱,۵۵۶,۰۹۳	۳۹,۹۰۰ برابر
تعداد نوع رابطه	۵	۹۶	۱۹ برابر
برچسب طلایی	ندارد	دارد	—

۸. گزینه‌های بزرگ دیگر که بررسی شد

دیتاست	اندازه	چرا انتخاب نشد
T-REx	۳/۰۹ میلیون چکیده، ۱۱ میلیون سه‌تایی	فقط برچسب ازدور دارد و بخش انسانی برای F1 ندارد؛ اجرای کامل با مدل زبانی حدود ۳۰ برابر DocRED هزینه دارد.
Wikidata5M	۴/۶ میلیون موجودیت، ۲۰ میلیون سه‌تایی	برای تکمیل گراف ساخته شده، نه استخراج رابطه از متن؛ شاهد جمله‌ای ندارد.
REBEL	چند میلیون چکیده، ۲۲۰ رابطه	برچسب ازدور با فیلتر خودکار؛ ارزیابی انسانی استاندارد ندارد.
FarsBase-KBP (فارسی)	۲۲ هزار سه‌تایی	داده به‌صورت عمومی منتشر نشده است.

از میان گزینه‌های بالا، DocRED تنها موردی بود که هم‌زمان هر سه چیز را داشت: مقیاس صدهزار سندی، برچسب انسانی برای ارزیابی استاندارد، و لایسنس آزاد.

۹. برنامه‌ی اجرا

فاز	کار	وضعیت
۱	انتخاب و دریافت پیکره‌ی کامل (۱۰۶,۹۲۴ سند)	انجام شد
۲	اجرای مدل روی هر چهار بخش با استخراج هم‌زمان و قابل‌ازسرگیری	در حال اجرا (بخش‌های انسانی تمام، بخش ازدور در جریان)
۳	ارزیابی F1 / Ign F1 روی dev و test و گزارش توافق روی بخش ازدور	پس از پایان فاز ۲
۴	بارگذاری گراف چندمیلیونی در Neo4j و رابط جست‌وجو	بارگذار دسته‌ای آماده است
۵	فصل آخر: مطالعه‌ی موردی شهرداری با همان مدل	انجام شد

۱۰. فایل‌ها

فایل	حجم	محتوا
data/benchmark/docred/*.parquet	۱۰۶ مگابایت	چهار بخش پیکره، قالب Parquet رسمی HuggingFace
data/benchmark/docred/stats.json, stats_detail.json	—	آمار محاسبه‌شده‌ی این سند
docs/dataset_re_docred.zip	۴/۷ مگابایت	برچسب‌های بازبینی‌شده‌ی (Re-test/dev DocRED)
DATASET_PROPOSAL.md	—	همین سند