

# پیشنهاد دیتاست اصلی پروژه – فاز ۱

**پروژه:** ساخت گراف دانش از متن غیرساختاریافته **دیتاست پیشنهادی: Re-DocRED** (نسخه بازبینی شده و اصلاح شده ی DocRED) **زبان:** انگلیسی • **لایسنس:** MIT (استفاده و انتشار آزاد) **منبع رسمی:** Yao et al., *DocRED: A Large-Scale* **مقاله مرجع دیتاست پایه:** <https://github.com/tonytan48/Re-DocRED> **مقاله** */ Document-Level Relation Extraction Dataset*, ACL 2019 – <https://aclanthology.org/P19-1074> **نسخه اصلاح شده:** Tan et al., *Revisiting DocRED – Addressing the False Negative Problem*, EMNLP 2022

## ۱. چرا این دیتاست

مسئله ی پروژه، **استخراج رابطه در سطح سند** است: ورودی یک متن چندجمله ای است و خروجی مجموعه ای از سه تایی های (موجودیت، رابطه، موجودیت) همراه با شاهد متنی.

Re-DocRED دقیقاً همین مسئله را با برچسب طلایی انسانی می سنجد:

- برچسب طلایی دارد، پس **دقت، بازخوانی و F1 واقعی** قابل محاسبه است. دیتاست شهرداری برچسب طلایی ندارد و فقط ارزیابی دستی می دهد.
- **بنچمارک استاندارد جهانی** است. نتیجه ی ما با نتایج منتشر شده در ACL و EMNLP قابل مقایسه است.
- هر سه تایی **شماره ی جمله ی شاهد** را ذخیره می کند. این دقیقاً با طراحی فعلی سامانه ی ما (ذخیره ی evidence برای هر یال) هم راستا است.
- لایسنس MIT است و بدون درخواست مجوز قابل دانلود و ارسال است.

## ۲. جدول ۱ – ابعاد کلی دیتاست (اعداد از روی فایل های واقعی محاسبه شد)

| بخش   | تعداد سند | تعداد جمله | تعداد توکن | تعداد موجودیت | تعداد ذکر (mention) | تعداد سه تایی |
|-------|-----------|------------|------------|---------------|---------------------|---------------|
| Train | ۳,۰۵۳     | ۲۴,۲۵۶     | ۶۰۳,۴۶۸    | ۵۹,۳۵۹        | ۷۹,۴۸۱              | ۸۵,۹۳۲        |
| Dev   | ۵۰۰       | ۴,۱۱۰      | ۱۰۱,۹۷۰    | ۹,۶۸۴         | ۱۳,۱۸۹              | ۱۷,۲۸۴        |
| Test  | ۵۰۰       | ۳,۹۶۶      | ۹۸,۷۳۴     | ۹,۷۷۹         | ۱۳,۰۱۸              | ۱۷,۴۴۸        |
| جمع   | ۴,۰۵۳     | ۳۲,۳۳۲     | ۸۰۴,۱۷۲    | ۷۸,۸۲۲        | ۱۰۵,۶۸۸             | ۱۲۰,۶۶۴       |

| شاخص                      | مقدار             |
|---------------------------|-------------------|
| تعداد نوع رابطه           | ۹۶                |
| تعداد نوع موجودیت         | ۶                 |
| میانگین جمله در هر سند    | ۸/۰               |
| میانگین توکن در هر سند    | ۱۹۸/۴             |
| میانگین موجودیت در هر سند | ۱۹/۴              |
| میانگین سه‌تایی در هر سند | ۲۹/۸              |
| حجم خام فایل‌ها           | ۲۴ مگابایت (JSON) |

### ۳. جدول ۲ – توزیع نوع موجودیت

| نوع موجودیت | معنی   | تعداد  | سهم   |
|-------------|--------|--------|-------|
| LOC         | مکان   | ۲۳,۱۷۴ | ۲۹/۴% |
| TIME        | زمان   | ۱۵,۱۴۰ | ۱۹/۲% |
| MISC        | سایر   | ۱۲,۴۵۹ | ۱۵/۸% |
| PER         | شخص    | ۱۲,۲۷۷ | ۱۵/۶% |
| ORG         | سازمان | ۱۰,۷۳۵ | ۱۳/۶% |
| NUM         | عدد    | ۵,۰۳۷  | ۶/۴%  |
| جمع         |        | ۷۸,۸۲۲ | ۱۰۰%  |

### ۴. جدول ۳ – ده رابطه‌ی پرتکرار (از ۹۶ رابطه)

شناسه‌ها، شناسه‌ی خصیصه‌ی Wikidata هستند.

| رتبه | شناسه | معنی                       | تعداد  |
|------|-------|----------------------------|--------|
| ۱    | P131  | واقع در واحد تقسیمات کشوری | ۲۸,۲۹۶ |
| ۲    | P17   | کشور                       | ۱۹,۹۰۶ |
| ۳    | P27   | تابعیت                     | ۶,۲۶۹  |
| ۴    | P150  | شامل واحد تقسیمات کشوری    | ۴,۷۶۴  |
| ۵    | P800  | اثر شاخص                   | ۴,۲۵۷  |
| ۶    | P527  | دارای جزء                  | ۳,۳۰۷  |
| ۷    | P361  | جزئی از                    | ۳,۰۱۲  |
| ۸    | P175  | اجراکننده                  | ۲,۳۸۶  |
| ۹    | P577  | تاریخ انتشار               | ۲,۲۵۸  |
| ۱۰   | P463  | عضو                        | ۱,۸۷۷  |

## ۵. جدول ۴ – ویژگی‌های هر رکورد (Schema)

| فیلد                    | سطح   | نوع           | توضیح                     |
|-------------------------|-------|---------------|---------------------------|
| title                   | سند   | متن           | عنوان سند                 |
| sents                   | سند   | آرایه‌ی آرایه | جمله‌های سند، توکن‌شده    |
| vertexSet               | سند   | آرایه         | فهرست موجودیت‌ها          |
| vertexSet[i][j].name    | ذکر   | متن           | شکل ظاهری موجودیت در متن  |
| vertexSet[i][j].type    | ذکر   | برچسب         | یکی از ۶ نوع موجودیت      |
| vertexSet[i][j].sent_id | ذکر   | عدد           | شماره‌ی جمله              |
| vertexSet[i][j].pos     | ذکر   | بازه          | موقعیت توکنی شروع و پایان |
| labels[k].h             | رابطه | اندیس         | موجودیت مبدأ              |
| labels[k].t             | رابطه | اندیس         | موجودیت مقصد              |
| labels[k].r             | رابطه | برچسب         | یکی از ۹۶ رابطه           |
| labels[k].evidence      | رابطه | آرایه         | شماره‌ی جمله‌های شاهد     |

تعداد ویژگی متمایز: ۱۱ (۳ ویژگی در سطح سند، ۴ در سطح ذکر موجودیت، ۴ در سطح رابطه).

## ۶. چرا این دیتاست به اندازه‌ی کافی بزرگ و چالشی است

۶.۱ استدلال چندجمله‌ای اجباری. ۶۴,۵۲۴ سه‌تایی، یعنی ۵/۵۳٪ کل رابطه‌ها، بین دو موجودیتی است که هرگز در یک جمله با هم ظاهر نمی‌شوند. مدل باید از چند جمله و از زنجیره‌ی هم‌مرجعی عبور کند. یک مدل جمله‌محور روی نیمی از داده صفر می‌گیرد.

۶.۲ نامتوازن‌ی شدید کلاس. تعداد کل جفت‌موجودیت‌های نامزد ۱,۵۸۴,۹۹۴ است، اما فقط ۱۲۰,۶۶۴ جفت رابطه دارند. نرخ مثبت ۷/۶۱٪ است. یعنی مدل باید ۹۲/۴٪ موارد را درست رد کند. این همان مسئله‌ی «توهم رابطه» است که در پروژه‌ی شهرداری هم با اعتبارسنجی سخت‌گیرانه کنترل کردیم.

۶.۳ فضای برچسب بزرگ و دنباله‌دار. ۹۶ نوع رابطه وجود دارد، اما ۵ رابطه‌ی نخست ۵۲/۶٪ کل نمونه‌ها را می‌گیرند و ۷ رابطه کمتر از ۱۰۰ نمونه دارند. مدل باید روی کلاس‌های کم‌نمونه هم کار کند.

۶.۴ چندبرچسبی بودن. ۲۴,۶۳۶ جفت‌موجودیت بیش از یک رابطه‌ی هم‌زمان دارند. پس مسئله دسته‌بندی تک‌برچسبی نیست و ارزیابی باید چندبرچسبی باشد.

۶.۵ هم‌مرجعی و حل موجودیت. ۱۰۵,۶۸۸ ذکر به ۷۸,۸۲۲ موجودیت نگاشت می‌شود و ۱۸/۶٪ موجودیت‌ها بیش از یک ذکر دارند. نام‌های «Willi Schneider» و «Schneider» باید به یک گره برسند. این همان مشکلی است که در دیتاست شهرداری برای ردیف‌های بودجه دیدیم و با کلید یکتاسازی حل کردیم – اینجا در مقیاس ۷۹ هزار موجودیت.

۶.۶ ارزیابی سخت‌گیرانه و قابل مقایسه. دیتاست دو معیار دارد: F1 و Ign F1 (که سه‌تایی‌های دیده‌شده در آموزش را حذف می‌کند تا حفظ‌کردن جواب امتیاز نگیرد). این معیار جلوی تقلب مدل را می‌گیرد.

۶.۷ مقیاس محاسباتی. ۸۰۴,۱۷۲ توکن و ۱/۵۸ میلیون جفت نامزد یعنی خط لوله باید دسته‌ای، قابل‌ازسرگیری و بدون تکرار کار باشد. معماری فعلی ما (کش در سطح chunk و بارگذاری idempotent در Neo4j) دقیقاً برای همین ساخته شده است.

## ۷. مقایسه با دیتاست شهرداری (که به عنوان مطالعه موردی می ماند)

| شاخص                | دیتاست شهرداری | Re-DocRED | نسبت        |
|---------------------|----------------|-----------|-------------|
| تعداد سند           | ۷              | ۴,۰۵۳     | ۵۷۹ برابر   |
| تعداد توکن          | ۸۱۱            | ۸۰۴,۱۷۲   | ۹۹۲ برابر   |
| تعداد موجودیت       | ۳۸             | ۷۸,۸۲۲    | ۲,۰۷۴ برابر |
| تعداد سه تایی       | ۳۹             | ۱۲۰,۶۶۴   | ۳,۰۹۴ برابر |
| تعداد نوع رابطه     | ۵              | ۹۶        | ۱۹ برابر    |
| برچسب طلایی         | ندارد          | دارد      | —           |
| رابطه ی بین جمله ای | کم             | ۵۳/۵%     | —           |

## ۸. گزینه های فارسی که بررسی شد

| دیتاست        | اندازه               | چرا انتخاب نشد                                                                   |
|---------------|----------------------|----------------------------------------------------------------------------------|
| PERLEX        | ۱۰,۶۹۰ جمله، ۹ رابطه | سطح جمله است، نه سطح سند. استدلال چندجمله ای ندارد. اندازه ی برچسب کوچک است.     |
| FarsBase-KBP  | ۲۲,۰۱۵ سه تایی فارسی | فایل داده به صورت عمومی و آزاد در دسترس نیست و نیاز به مکاتبه با نویسندگان دارد. |
| ARMAN / PEYMA | فقط NER              | رابطه ندارد، پس برای گراف دانش ناقص است.                                         |

اگر استاد محترم اصرار بر دیتاست فارسی داشته باشند، **FarsBase-KBP** گزینه ی دوم است و برای دریافت آن با نویسندگان مکاتبه می کنیم.

## ۹. برنامه‌ی اجرا مطابق نظر استاد

| فاز              | کار                                                                           | خروجی                   |
|------------------|-------------------------------------------------------------------------------|-------------------------|
| فاز ۱ (انجام شد) | انتخاب و دریافت دیتاست بزرگ و چالشی                                           | همین سند + فایل داده    |
| فاز ۲            | نگاشت هستان‌شناسی Re-DocRED به خط لوله‌ی فعلی و اجرا روی زیرمجموعه‌ی Dev/Test | سه‌تایی‌های استخراج‌شده |
| فاز ۳            | ارزیابی کمی با F1 و lgn F1 و مقایسه با نتایج منتشرشده                         | جدول نتایج              |
| فاز ۴            | فصل آخر: اجرای همان مدل روی دیتاست شهرداری به‌عنوان مطالعه‌ی موردی ایرانی     | گزارش مطالعه موردی      |

## ۱۰. فایل‌های پیوست

| فایل                  | حجم         | محتوا                                                                              |
|-----------------------|-------------|------------------------------------------------------------------------------------|
| dataset_re_docred.zip | ۴/۷ مگابایت | کل دیتاست: train_revised.json، dev_revised.json، test_revised.json به‌همراه لایسنس |
| re_docred_sample.json | ۳۷ کیلوبایت | دو سند نمونه با قالب خوانا، برای بررسی سریع ساختار                                 |
| DATASET_PROPOSAL.md   | —           | همین سند                                                                           |