

ساخت خودکار گراف دانش از متن غیرساختاریافته با مدل‌های زبانی و هستان‌شناسی مقید

نویسنده: مصطفی رستگار دیتاست اصلی: DocRED، پیکره‌ی کامل (انگلیسی، ۱۰۶,۹۲۴ سند، ۱,۵۵۶,۰۹۳ سه‌تایی برچسب‌خورده) به همراه برچسب‌های بازبینی‌شده‌ی Re-DocRED برای ۴,۰۵۳ سند آن مطالعه‌ی موردی (فصل آخر): اسناد شهرداری تهران (فارسی)

چکیده

در این پروژه سامانه‌ای ساخته‌ایم که از متن آزاد سه‌تایی‌های (موجودیت، رابطه، موجودیت) بیرون می‌کشد و آن‌ها را در یک گراف دانش قابل پرس‌وجو می‌نشانند. آنچه سامانه را از یک فراخوانی ساده‌ی مدل زبانی جدا می‌کند سه تصمیم است: هستان‌شناسی مقید که خروجی نامعتبر را رد می‌کند، الزام شاهد که هر یال را به جمله‌ی منبعش می‌بندد، و خط لوله‌ای که اجرای دوباره‌اش داده‌ی تکراری نمی‌سازد.

سامانه روی بنچمارک استاندارد Re-DocRED ارزیابی شد. در شش تکرار، $F1$ از $۱۶/۸۸$ به $۲۹/۶۶$ رسید (۷۶٪ رشد نسبی)، در حالی که خط‌مبنای منتشرشده با GPT-3.5 روی همین دیتاست $۹/۷۴$ است. هیچ مرحله‌ی آموزش گرادانی انجام نشد، ولی سامانه بدون نظارت نیست: هستان‌شناسی و مثال‌های پرامپت هر دو از بخش Train مشتق شده‌اند (بخش ۴/۶). سه عامل این رشد را ساختند: مثال کاری در پرامپت که دقت را ۲۴٪ بالا برد، لایه‌ی بستر قاعده‌محور، و اجماع چند گذر مستقل.

سپس سامانه روی کل ۵۰۰ سند بخش Dev اجرا شد و $F1 = ۲۸/۶۴$ گرفت. اختلاف با عدد زیرمجموعه کمتر از یک واحد است، پس نتیجه به یک نمونه‌ی کوچک وابسته نیست.

در مرحله‌ی سوم، دیتاست به پیکره‌ی کامل DocRED گسترش یافت: ۱۰۶,۹۲۴ سند و ۱/۵۶ میلیون سه‌تایی برچسب‌خورده، ۲۶ برابر بزرگ‌تر از مرحله‌ی قبل. برای این مقیاس، استخراج هم‌زمان (۴۸ درخواست موازی)، ازسرگیری بدون تکرار کار، ارزیاب جریانی و بارگذار دسته‌ای Neo4j ساخته شد. روی ۹۹۸ سند بخش Dev با برچسب‌های اصلی $F1$ DocRED، برابر $۲۱/۳۸$ شد. همان پیش‌بینی‌ها روی ۴۹۸ سند مشترک، با برچسب‌های اصلی $۲۱/۰۳$ و با برچسب‌های بازبینی‌شده $۲۶/۶۴$ می‌گیرند؛ دقت از $۱۶/۸$ به $۳۵/۶$ دو برابر می‌شود. این اندازه‌گیری مستقیم اثر منفی کاذب در برچسب‌های اصلی است که مقاله‌ی Re-DocRED به آن اشاره می‌کند. در پایان همان مدل بدون تغییر معماری روی اسناد فارسی شهرداری اجرا شد و به‌عنوان مطالعه‌ی موردی ایرانی گزارش شد.

۱. مقدمه

بخش بزرگی از دانش هر سازمانی جایی ذخیره نشده که بشود از آن پرس و جو گرفت؛ در متن آزاد پراکنده است. برای پاسخ به پرسشی به ظاهر ساده – مثلاً اینکه مجری فلان پروژه چه شرکتی بوده، یا فلان شخص تابع کدام کشور است – باید ده ها سند را دستی خواند و کنار هم گذاشت.

گراف دانش راه حل شناخته شده ای این وضعیت است: متن به گره و یال تبدیل می شود و پرسش، به جای خواندن، با یک پرس و جو پاسخ می گیرد.

آنچه در این پروژه دنبال کردیم، استخراج رابطه در سطح سند (Document-level Relation Extraction) است. ورودی یک متن چندجمله ای است و خروجی مجموعه ای از سه تایی ها که هر کدام به جمله ی منبع خود گره خورده اند. دو چیز کار را سخت می کند.

نخست اینکه رابطه معمولاً در یک جمله جمع نشده است؛ مدل باید چند جمله را دنبال کند و از زنجیره ی هم مرجعی رد شود. دوم، و مهم تر، اینکه مدل زبانی رابطه ی نادرست می سازد. برای یک گراف دانش این خطا از خطای معمول بدتر است، چون یک یال غلط یک بار وارد می شود و بعد برای همیشه در پایگاه داده می ماند و به پرسش های بعدی هم سرایت می کند.

۲. کار پیشین

رویکرد	نقطه ی قوت	نقطه ی ضعف
استخراج قاعده محور (Rule-based / OpenIE)	شفاف و بدون نیاز به داده	الگوی دستی، شکننده، پوشش کم، برای فارسی ضعیف
مدل های نظارت شده ی RE (ATLOP، KD-RE، GLiDRE، DocRE)	دقت بالا روی بنچمارک	نیازمند هزاران سند برچسب خورده که در دامنه ی فارسی وجود ندارد
استخراج با مدل زبانی بزرگ (zero-shot)	بدون داده ی آموزشی کار می کند	مستعد تولید رابطه ی نادرست و خارج از دامنه
پایگاه داده ی گرافی (Neo4j)	بستر استاندارد ذخیره و پرس و جو	خودش استخراج نمی کند

کار حاضر در دسته ی سوم است، ولی خطای آن را با یک لایه ی نمادین (symbolic) مهار می کند. این ترکیب در ادبیات **Neuro-symbolic Knowledge Graph Construction** نامیده می شود.

۳. نوآوری کار

ایده‌ی محوری این است که به مدل زبانی اعتماد نکنیم و خروجی‌اش را از چند صافی رد کنیم. پنج جزء زیر روی هم این کار را انجام می‌دهند.

۳.۱ هستان‌شناسی مقید. سه‌تایی تنها وقتی پذیرفته می‌شود که ترکیب (نوع فاعل، رابطه، نوع مفعول) آن در فهرست مجاز باشد؛ هر چیز دیگری بی‌چون‌وچرا کنار گذاشته می‌شود. این صافی در اجرای روی Re-DocRED یک‌پنجم خروجی مدل (۲۰/۳٪) را رد کرد، و همان‌طور که در بخش ۶/۴ نشان می‌دهیم، بهایی که بابتش پرداختیم تنها ۲۱/۰٪ از بازخوانی بود.

۳.۲ شاهد اجباری. هر یال باید عین جمله‌ی منبع را با خود حمل کند و یال بی‌شاهد اصلاً وارد گراف نمی‌شود. حاصلش این است که هیچ ادعایی در گراف نمی‌ماند که نشود آن را تا متن اصلی دنبال کرد.

۳.۳ لایه‌ی بستار قاعده‌محور. مدل زبانی آنچه را می‌گوید که در جمله نوشته شده؛ اما گراف دانش باید آنچه را هم نگه دارد که از خود گراف نتیجه می‌شود. سه قاعده روی گراف اجرا می‌شوند و حقیقت‌های تازه می‌سازند. نکته‌ی طراحی اینجا است که هر حقیقت استنتاجی شاهد مقدمه‌هایش را به ارث می‌برد، پس قانون بند قبل زیر پا گذاشته نمی‌شود.

۳.۴ خط لوله‌ی idempotent. سند تازه اضافه کنید و دوباره اجرا کنید؛ نه سند تکراری ساخته می‌شود، نه قطعه، نه سه‌تایی، نه گره و نه یال. این را با کلید پایدار entity_key برای گره‌ها، fact_id مبتنی بر sha1 برای یال‌ها و کش در سطح chunk_sha به دست آوردیم.

۳.۵ ورودی چندقابلی. علاوه بر PDF و DOCX و TXT، تصویر (PNG/JPG) هم پذیرفته می‌شود و با مدل vision رونویسی می‌گردد.

۴. متدلوژی

۴.۱ معماری سه‌مرحله‌ای

مرحله	ورودی ← خروجی	کار
۱) ورود و پاک‌سازی	سند خام ← قطعه‌ی متنی	استخراج متن، نرمال‌سازی (hazm برای فارسی)، قطعه‌بندی، ثبت chunk_sha
۲) استخراج دانش	قطعه ← سه‌تایی	فراخوانی مدل زبانی، اعتبارسنجی Pydantic، رد موارد خارج از هستان‌شناسی، الزام شاهد، حذف تکراری با fact_id
۳) بستار و بارگذاری	سه‌تایی ← گراف	اجرای سه قاعده‌ی استنتاج، سپس MERGE گره و یال در Neo4j

۴.۲ هستان‌شناسی

هستان‌شناسی از سامانه جدا است و از فایل JSON خوانده می‌شود (فلگ --ontology). این تصمیم طراحی باعث شد همان‌کد بدون بازنویسی روی دو دیتاست کاملاً متفاوت کار کند:

دیتاست	منبع هستان‌شناسی	نوع موجودیت	رابطه	ترکیب مجاز
شهرداری (فارسی)	دست‌نویس	۶	۵	۵
Re-DocRED (انگلیسی)	خودکار از بخش Train	۶	۹۶	۶۵۴

برای Re-DocRED هیچ قاعده‌ای دست‌نویس نشد. ۶۵۴ ترکیب مجاز از روی داده‌ی آموزشی محاسبه شد.

۴.۳ لایه‌ی بستر قاعده‌محور

قاعده	منطق
R1 معکوس	$A \text{ در } B \text{ واقع است} \Rightarrow B \text{ شامل } A \text{ است}$
R2 تراگذاری	$A \text{ در } B \text{ و } B \text{ در } A \Rightarrow C \text{ در } C$
R3 زنجیره	$A \text{ در } B \text{ و } B \text{ کشورش } A \Rightarrow C \text{ کشورش } C$

۴.۴ پشته‌ی فناوری

PyMuPDF، Python، hazm، python-docx، مدل openai/gpt-4.1-mini با دمای ۰، Pydantic برای اعتبارسنجی، tenacity برای تلاش دوباره، Neo4j 5 روی Docker، و FastAPI به‌همراه vis-network برای رابط وب.

۵. دیتاست اصلی – پیکره‌ی کامل DocRED و برچسب‌های بازبینی‌شده‌ی Re-

DocRED

منبع DocRED: <https://github.com/thunlp/DocRED> · نسخه‌ی Parquet:

<https://huggingface.co/datasets/thunlp/docred> · لایسنس: MIT مقاله‌ی پایه: Yao et al., DocRED, ACL

۲۰۱۹ برچسب‌های بازبینی‌شده: Tan et al., Revisiting DocRED – Addressing the False Negative Problem,

EMNLP 2022 – <https://github.com/tonytan48/Re-DocRED>

کار در دو مرحله روی این داده انجام شد. مرحله‌ی نخست روی Re-DocRED بود: همان ۴,۰۵۳ سند برچسب‌خورده‌ی انسانی DocRED، با برچسب‌هایی که بازبینی و کامل شده‌اند. مرحله‌ی دوم کل پیکره‌ی DocRED را برداشت که ۲۶ برابر بزرگ‌تر است و بخش عمده‌اش با هم‌ترازی Wikidata برچسب خورده (نظارت‌ازدور).

۵.۰ جدول ۰ – پیکره‌ی کامل DocRED

اعداد با `python -m src.docred stats` از روی فایل‌های Parquet محاسبه شد و در `data/benchmark/docred/stats.json` ذخیره است.

بخش	نوع برچسب	سند	جمله	واژه	موجودیت	ذکر	سه‌تایی
train_annotated	انسانی	۳,۰۵۳	۲۴,۲۵۶	۶۰۳,۴۶۸	۵۹,۴۹۳	۷۹,۴۸۱	۳۸,۱۸۰
validation (dev)	انسانی	۹۹۸	۸,۰۵۷	۲۰۰,۰۷۷	۱۹,۵۲۸	۲۶,۱۴۱	۱۲,۲۷۵
test	مخفی (لیدربرد)	۱,۰۰۰	—	۱۹۷,۷۸۷	۱۹,۵۳۹	۲۶,۷۰۴	—
train_distant	نظارت‌ازدور	۱۰۱,۸۷۳	۸۲۸,۱۱۵	۲۰,۳۲۸,۸۵۸	۱,۹۶۵,۴۸۴	۲,۵۵۸,۳۵۰	۱,۵۰۵,۶۳۸
جمع		۱۰۶,۹۲۴		۲۱,۳۳۰,۱۹۰	۲,۰۶۴,۰۴۴	۲,۶۹۰,۶۷۶	۱,۵۵۶,۰۹۳

شاخص	مقدار
جفت‌موجودیت نامزد	۴۱٫۱ میلیون
نرخ مثبت	۳٫۸٪
سه‌تایی بین‌جمله‌ای (بخش نظارت‌ازدور)	۸۶۷,۶۳۴ (۵۷٫۶٪)
جفت‌موجودیت با بیش از یک رابطه	۱۵۱,۶۷۹
حجم خام	۳۸۰ مگابایت JSONL

دو نکته درباره‌ی برچسب‌ها. نخست، برچسب‌های اصلی DocRED ناقص‌اند: مقاله‌ی Re-DocRED نشان داد بسیاری از رابطه‌های موجود در متن برچسب نخورده‌اند. بخش ۷٫۸ این ناقص بودن را با همان پیش‌بینی‌ها و دو مجموعه برچسب اندازه می‌گیرد. دوم، برچسب‌های بخش نظارت‌ازدور از هم‌ترازی خودکار با Wikidata می‌آیند، نه از انسان؛ روی این بخش «توافق با برچسب ازدور» گزارش می‌شود، نه F1.

۵.۱ جدول ۱ – ابعاد کلی برچسب‌های بازبینی‌شده (Re-DocRED)

اعداد از روی فایل‌های واقعی محاسبه شد، نه از مقاله نقل شد.

بخش	سند	جمله	توکن	موجودیت	ذکر (mention)	سه‌تایی
Train	۳,۰۵۳	۲۴,۲۵۶	۶۰۳,۴۶۸	۵۹,۳۵۹	۷۹,۴۸۱	۸۵,۹۳۲
Dev	۵۰۰	۴,۱۱۰	۱۰۱,۹۷۰	۹,۶۸۴	۱۳,۱۸۹	۱۷,۲۸۴
Test	۵۰۰	۳,۹۶۶	۹۸,۷۳۴	۹,۷۷۹	۱۳,۰۱۸	۱۷,۴۴۸
جمع	۴,۰۵۳	۳۲,۳۳۲	۸۰۴,۱۷۲	۷۸,۸۲۲	۱۰۵,۶۸۸	۱۲۰,۶۶۴

شخص	مقدار
نوع رابطه	۹۶
نوع موجودیت	۶
میانگین جمله در هر سند	۸,۰
میانگین توکن در هر سند	۱۹۸,۴
میانگین موجودیت در هر سند	۱۹,۴
میانگین سه‌تایی در هر سند	۲۹,۸
حجم خام	۲۴ مگابایت JSON

۵.۲ جدول ۲ – توزیع نوع موجودیت

نوع	معنی	تعداد	سهم
LOC	مکان	۲۳,۱۷۴	۲۹,۴%
TIME	زمان	۱۵,۱۴۰	۱۹,۲%
MISC	سایر	۱۲,۴۵۹	۱۵,۸%
PER	شخص	۱۲,۲۷۷	۱۵,۶%
ORG	سازمان	۱۰,۷۳۵	۱۳,۶%
NUM	عدد	۵,۰۳۷	۶,۴%
جمع		۷۸,۸۲۲	۱۰۰%

۵.۳ جدول ۳ – ده رابطه‌ی پرتکرار (از ۹۶)

رتبه	شناسه‌ی Wikidata	معنی	تعداد
۱	P131	واقع در واحد تقسیمات کشوری	۲۸,۲۹۶
۲	P17	کشور	۱۹,۹۰۶
۳	P27	تابعیت	۶,۲۶۹
۴	P150	شامل واحد تقسیمات کشوری	۴,۷۶۴
۵	P800	اثر شاخص	۴,۲۵۷
۶	P527	دارای جزء	۳,۳۰۷
۷	P361	جزئی از	۳,۰۱۲
۸	P175	اجراکننده	۲,۳۸۶
۹	P577	تاریخ انتشار	۲,۲۵۸
۱۰	P463	عضو	۱,۸۷۷

۵.۴ جدول ۴ – ویژگی‌های هر رکورد (Schema)

فیلد	سطح	نوع	توضیح
title	سند	متن	عنوان سند
sents	سند	آرایه‌ی آرایه	جمله‌های توکن‌شده
vertexSet	سند	آرایه	فهرست موجودیت‌ها
vertexSet[i][j].name	ذکر	متن	شکل ظاهری در متن
vertexSet[i][j].type	ذکر	برچسب	یکی از ۶ نوع
vertexSet[i][j].sent_id	ذکر	عدد	شماره‌ی جمله
vertexSet[i][j].pos	ذکر	بازه	موقعیت توکنی
labels[k].h	رابطه	اندیس	موجودیت مبدأ
labels[k].t	رابطه	اندیس	موجودیت مقصد
labels[k].r	رابطه	برچسب	یکی از ۹۶ رابطه
labels[k].evidence	رابطه	آرایه	شماره‌ی جمله‌های شاهد

تعداد ویژگی متمایز: ۱۱ – ۳ در سطح سند، ۴ در سطح ذکر، ۴ در سطح رابطه.

۵.۵ چرا این دیتاست چالشی است

۵.۵.۱ استدلال چندجمله‌ای اجباری. ۶۴,۵۲۴ سه‌تایی – یعنی ۵/۵۳٪ کل رابطه‌ها – میان دو موجودیتی برقرار است که هرگز در یک جمله کنار هم نمی‌آیند. عملاً یعنی هر مدل جمله‌محوری روی بیش از نیمی از این داده صفر می‌گیرد، هرچقدر هم در سطح جمله خوب کار کند.

۵.۵.۲ نامتوازن شدید کلاس. تعداد جفت‌موجودیت نامزد ۱,۵۸۴,۹۹۴ است، ولی فقط ۱۲۰,۶۶۴ جفت رابطه دارند. نرخ مثبت ۷/۶۱٪ است. مدل باید ۹۲/۴٪ موارد را درست رد کند. این دقیقاً همان مسئله‌ی مهار توهم است.

۵.۵.۳ فضای برچسب بزرگ و دنباله‌دار. ۹۶ رابطه وجود دارد، ولی ۵ رابطه‌ی نخست ۵۲/۶٪ نمونه‌ها را می‌گیرند و ۷ رابطه کمتر از ۱۰۰ نمونه دارند.

۵.۵.۴ چندبرچسبی بودن. ۲۴,۶۳۶ جفت‌موجودیت بیش از یک رابطه‌ی هم‌زمان دارند. پس ارزیابی باید چندبرچسبی باشد.

۵.۵.۵ هم‌مرجعی و حل موجودیت. ۱۰۵,۶۸۸ ذکر به ۷۸,۸۲۲ موجودیت نگاشت می‌شود و ۱۸/۶٪ موجودیت‌ها بیش از یک ذکر دارند. «Willi Schneider» و «Schneider» باید به یک گره برسند.

۵.۵.۶ مقیاس محاسباتی. ۸۰۴,۱۷۲ توکن و ۱/۵۸ میلیون جفت نامزد یعنی خط لوله باید دسته‌ای، قابل ازسرگیری و بدون تکرار کار باشد.

۵.۶ گزینه‌های فارسی که بررسی و رد شد

دیتاست	اندازه	چرا انتخاب نشد
PERLEX	۱۰,۶۹۰ جمله، ۹ رابطه	سطح جمله است، نه سطح سند. استدلال چندجمله‌ای ندارد.
FarsBase-KBP	۲۲,۰۱۵ سه‌تایی فارسی	فایل داده به‌صورت عمومی در دسترس نیست. نیاز به مکاتبه با نویسندگان دارد.
ARMAN / PEYMA	فقط NER	رابطه ندارد، پس برای گراف دانش ناقص است.

۶. آرایش آزمایش و معیارها

۶.۱ آرایش

آرایش استاندارد این بنچمارک رعایت شد: فهرست موجودیت‌های هر سند به مدل داده می‌شود و مدل باید رابطه‌های بین آن‌ها را پیدا کند و برای هر رابطه جمله‌ی شاهد را نقل کند.

بخش سامانه	تغییر برای Re-DocRED
قطعه‌بندی و پیش‌پردازش	بدون تغییر
فراخوانی مدل زبانی	بدون تغییر
اعتبارسنجی Pydantic	بدون تغییر
شاهد اجباری	بدون تغییر
حذف تکراری با fact_id	بدون تغییر
هستان‌شناسی	از فایل JSON خوانده می‌شود

۶.۲ معیارها

- **Precision / Recall / F1** روی مجموعه‌ی سه‌تایی‌های (سند، موجودیت مبدأ، رابطه، موجودیت مقصد).
- **Ign F1** معیار سخت‌گیرانه‌ی DocRED. هر حقیقتی که در بخش Train هم دیده شده، از هر دو طرف (طلایی و پیش‌بینی) حذف می‌شود، تا حفظ‌کردن جواب امتیاز نگیرد.

۶.۳ اعتبارسنجی خود ارزیاب

پیش از باور کردن هر عددی، خود ارزیاب آزمایش شد. شش تست آفلاین (بدون شبکه و بدون مدل زبانی) اجرا می‌شود:

تست	چه چیزی را ثابت می‌کند
اوراکل	پاسخ کامل درست باید ~۱۰۰ بگیرد
نصف بازخوانی	نصف پاسخ باید دقت ۱۰۰ و بازخوانی ~۵۰ بگیرد
موجودیت ناشناخته	نام نامعتبر باید حذف شود، نه اینکه امتیاز بگیرد
شکل ظاهری متفاوت	ذکر دیگر همان موجودیت باید به همان گره برسد
مجموعه‌ی Ign	مجموعه‌ی Ign باید کوچک‌تر از مجموعه‌ی کامل باشد
قاعده‌های بستر	R1، R2 و R3 باید فعال شوند و هر حقیقت استنتاجی شاهد داشته باشد

سقف نظری روش: پاسخ اوراکل $F1 = 99/62$ روی زیرمجموعه‌ی ۵۰ سند و $99/76$ روی کل ۵۰۰ سند Dev گرفت، نه ۱۰۰. علت: در چند سند دو موجودیت متفاوت با نام و نوع یکسان وجود دارد و با نام قابل تفکیک نیستند. پس سقف هر سامانه‌ی نام‌محور روی این داده حدود $99/7$ است و عدد مدل باید کنار این سقف خوانده شود.

۶.۴ سامانه دقیقاً از چه نظارتی استفاده می‌کند

این بخش برای جلوگیری از یک ادعای اغراق‌آمیز نوشته شده است. سامانه هیچ مرحله‌ی آموزش گرادینانی ندارد؛ هیچ وزنی به‌روز نمی‌شود. ولی «بدون نظارت» هم نیست. دو چیز از بخش Train گرفته شده است:

چه چیزی از Train آمده	چگونه استفاده می‌شود	کدام نسخه‌ها
هستان‌شناسی: ۶۵۴ ترکیب مجاز (نوع، رابطه، نوع)	هر سه‌تایی بیرون این فهرست رد می‌شود	v1 تا v6
دو سند نمونه با پاسخ کامل طلایی	داخل پرامپت به‌عنوان مثال کاری	v4 تا v6

پیامد مهم: چون هستان‌شناسی هر ترکیبی را که در Train دیده نشده ممنوع می‌کند، اگر ترکیب تازه‌ای فقط در Dev وجود داشته باشد، سامانه هرگز نمی‌تواند آن را پیش‌بینی کند. این یک سقف تحمیلی روی بازخوانی است که خودمان ساخته‌ایم.

این سقف اندازه‌گیری شد. از ۱۷,۲۸۴ حقیقت طلایی بخش Dev، فقط ۳۷ مورد (۰/۲۱٪) ترکیب نوعی دارند که در Train نیامده و فیلتر آن‌ها را ممنوع می‌کند؛ ۲۵ ترکیب متمایز، مانند MISC --league--> MISC. پس سقف بازخوانی تحمیل‌شده ۹۹/۷۹٪ است.

معامله‌ی این فیلتر روشن است: ۲۰/۳٪ خروجی مدل زبانی را می‌گیرد و در عوض ۰/۲۱٪ بازخوانی را می‌سوزاند. به همین دلیل نگه داشتنش به‌صرفه است.

واژه‌ی درست: نسخه‌ی «zero-shot» v1 با هستان‌شناسی مشتق از Train است و نسخه‌های v4 تا «few-shot» v6 با دو مثال. هیچ‌کدام «بی‌نظارت» نیستند. مقایسه‌ی مستقیم با خط‌مبنای zero-shot خالص، به سود ما است و در بخش ۷/۷ این هشدار تکرار شده است.

۶.۵ تنظیم روی Dev، و چرا این یک محدودیت است

پرامپت‌ها در شش تکرار ساخته شدند و هر تکرار روی همان بخش Dev سنجیده شد که عدد نهایی از آن گزارش می‌شود. تصمیم‌هایی مانند «اجماع کدام گذرها» و «کدام سه قاعده» پس از دیدن نتیجه‌ی Dev گرفته شدند، نه پیش از آن.

این یعنی عدد Dev کمی خوش‌بینانه است. راه درست، یک اجرای واحد روی Test با پیکربندی قفل‌شده است؛ این اجرا در مرحله‌ی سوم (بخش ۷/۸) با همین پیکربندی در جریان است و عددش پس از تکمیل گزارش می‌شود.

۶.۶ حساسیت به سخت‌گیری در تطبیق موجودیت

ارزیاب پاسخ را با نام به موجودیت طلایی نگاشت می‌کند. حالت پیش‌فرض، وقتی نوع پیش‌بینی‌شده با نوع طلایی نمی‌خواند، باز هم با نام تطبیق می‌دهد. این از نگاشت مبتنی بر اندیس بنچمارک اصلی آسان‌گیرتر است، پس ممکن است عدد را متورم کند.

برای اینکه این نگرانی حدس نماند، ارزیاب یک حالت سخت‌گیرانه هم دارد (--strict-types) که هر پیش‌بینی با نوع نادرست را دور می‌ریزد:

حالت تطبیق	پیش‌بینی پذیرفته	Precision	Recall	F1	Ign F1
پیش‌فرض (بازگشت به نام)	۱۱,۷۸۷	۳۵,۳۲	۲۴,۰۹	۲۸,۶۴	۲۸,۲۳
سخت‌گیرانه (نوع باید بخواند)	۱۱,۶۶۱	۳۵,۵۷	۲۴,۰۰	۲۸,۶۶	۲۸,۲۶

اختلاف ۰/۰۲ واحد است. پس آسان‌گیری تطبیق، عدد را متورم نکرده بود. ۱۲۶ پیش‌بینی که در حالت سخت‌گیرانه حذف شدند، بیشترشان به‌هرحال غلط بودند، برای همین دقت اندکی بالا رفت.

۶.۷ مهندسی مقیاس برای ۱۰۷ هزار سند

اجرای ۵۰۰ سند تک‌نخی حدود هفت ساعت طول کشیده بود. با همان سرعت، پیکره‌ی کامل بیش از یک ماه می‌گرفت. چهار تغییر این را ممکن کرد و هر چهار مورد روی داده‌ی واقعی اندازه‌گیری شد.

جزء	پیش از این	اکنون	اندازه‌گیری
استخراج	یک درخواست در هر لحظه، ۱۳ ثانیه بر سند	۴۸ درخواست هم‌زمان (workers) --	۱۵۰ تا ۲۲۰ سند در دقیقه، صفر شکست در ۱,۹۹۶ فراخوانی
ازسرگیری	سند بدون رابطه در خروجی ثبت نمی‌شد و در اجرای بعد دوباره پول می‌داد	فایل کناری empty سندهای بی‌رابطه را هم کش می‌کند	هیچ فراخوانی تکراری در ازسرگیری
بستار و ارزیاب	کل فایل در حافظه	جریانی، سند به سند، با اندیس بایتی	فایل ۱/۵ میلیون سطری بدون رشد حافظه؛ عدد ۵۰۰ سند عیناً بازتولید شد (۲۸,۶۴)
بارگذار Neo4j	چهار پرس‌وجو برای هر رابطه	دسته‌های ۲,۰۰۰ تایی با UNWIND، یک تراکنش بر دسته	۱۲,۴۳۷ رابطه در ۱۷/۵ ثانیه؛ اجرای دوباره صفر گره تازه ساخت

هزینه، اندازه‌گیری‌شده نه تخمینی. استخراج‌کننده مصرف توکن هر فراخوانی را از پاسخ سرویس می‌خواند و در فایل usage.json کنار خروجی می‌نویسد. روی ۸۹۸ سند بخش Dev:

گذر	توکن ورودی بر سند	از آن کش‌شده	توکن خروجی بر سند	زمان کل
A (بدون مثال)	۱,۱۱۵	۰	۱,۲۲۰	۲۸۰ ثانیه
B (دو مثال)	۸,۵۰۴	۷,۰۷۸ (۸۳٪)	۱,۴۶۷	۲۴۷ ثانیه

مثال‌های پرامپت هفت برابر ورودی را بزرگ می‌کنند، ولی چون پیشوند ثابت است، ۸۳٪ آن از کش سرویس می‌آید. توکن خروجی، نه ورودی، سهم اصلی هزینه است: هر رابطه با جمله‌ی شاهدش حدود ۴۰ توکن است. با قیمت

فهرست مدل، گذر A حدود ۰/۰۰۲۴ دلار و گذر B حدود ۰/۰۰۳۷ دلار بر سند تمام می‌شود؛ کل پیکره در گذر A حدود ۲۵۰ دلار.

۷. نتایج

زیرمجموعه: ۵۰ سند نخست بخش ۱,۸۶۸ Dev · سه‌تایی طلایی · ۸۵ رابطه‌ی متمایز · مدل openai/gpt-4.1-mini،
دما ·

۷.۱ جدول ۵ – شش تکرار

نسخه	توضیح	سه‌تایی خروجی	Precision	Recall	F1	Ign F1
v1	پرامپت پایه: «فقط چیزی را بده که متن می‌گوید»	۴۶۶	۴۲/۲۷	۱۰/۵۵	۱۶/۸۸	۱۹/۲۰
v2	پرامپت جامع: همه‌ی جفت‌ها + رابطه‌ی معکوس + استنتاج زنجیره‌ای	۷۱۶	۳۶/۴۵	۱۳/۹۷	۲۰/۲۰	۲۱/۰۶
v3	v2 + لایه‌ی بستر قاعده‌محور	۹۸۵	۳۴/۱۱	۱۷/۹۹	۲۳/۵۵	۲۳/۹۰
v4	v2 + دو مثال کاری در پرامپت (few-shot)	۵۰۱	۴۵/۱۱	۱۲/۱۰	۱۹/۰۸	۱۹/۸۶
v5	v4 + لایه‌ی بستر قاعده‌محور	۷۱۰	۴۵/۳۵	۱۷/۲۴	۲۴/۹۸	۲۵/۵۲
v6	اجماع سه گذر (v1+v2+v4) + لایه‌ی بستر	۱,۵۳۱	۳۲/۹۲	۲۶/۹۸	۲۹/۶۶	۲۹/۳۵

این جدول سه چیز به ما گفت.

نخست اینکه مثال در پرامپت دقت می‌خورد، نه بازخوانی. مقایسه‌ی v2 با v4 گویاست: دقت از ۳۶/۴۵ به ۴۵/۱۱ رفت، یعنی ۲۴٪ رشد نسبی، در حالی که تعداد خروجی کمتر شد. توضیحش ساده است – دو مثال کاری به مدل نشان می‌دهند چه ترکیب‌هایی مجازند، پس مدل از اول کمتر رابطه‌ی نامعتبر می‌سازد. رد شدن توسط فیلتر هستان‌شناسی هم از ۲۰/۳٪ به ۱۸/۷٪ افت کرد که همین را تأیید می‌کند.

دوم، لایه‌ی بستر روی هر دو پرامپت جواب داد و این دلگرم‌کننده بود: از v2 به v3 مقدار F1 را ۳/۳۵ واحد و از v4 به v5 آن را ۵/۹۰ واحد بالا برد.

سوم، و غیرمنتظره‌ترین یافته، اینکه بزرگ‌ترین جهش از جایی آمد که انتظارش را نداشتیم. سه گذر مستقل با پرامپت‌های متفاوت، مجموعه‌های متفاوتی از حقیقت‌ها پیدا می‌کنند؛ اجتماع ساده‌ی آن‌ها بازخوانی را از ۱۷/۲۴ به ۲۶/۹۸ و F1 را به ۲۹/۶۶ رساند. برداشت ما این است که گلوگاه سامانه هیچ‌وقت ندانستن نبود، بلکه کم‌گویی در یک گذر واحد بود.

از v1 به v6 مقدار F1 ۷۶٪ رشد نسبی داشت (۱۶/۸۸ ← ۲۹/۶۶).

Ign F1 معیار سخت‌گیرانه‌ی DocRED است. در همه‌ی نسخه‌ها Ign F1 نزدیک یا بالاتر از F1 است. این نشان می‌دهد سامانه از حافظه‌ی پیش‌آموخته‌ی مدل تغذیه نمی‌کند و از متن سند می‌خواند.

۷.۲ جدول ۶ – بازخوانی به تفکیک رابطه (ده رابطه‌ی پرتکرار)

رابطه	تعداد طلایی	v1	v2	v3	v4	v5	v6
located in the administrative territorial entity	۴۵۵	۹/۹٪	۱۸/۷٪	۲۶/۶٪	۱۱/۰٪	۱۹/۸٪	۳۵/۶٪
country	۳۵۱	۲/۰٪	۳/۷٪	۷/۱٪	۹/۷٪	۱۸/۲٪	۲۴/۲٪
contains administrative territorial entity	۱۱۵	۰٪	۶/۱٪	۲۵/۲٪	۲/۶٪	۲۲/۶٪	۳۳/۹٪
country of citizenship	۹۰	۱۲/۲٪	۲۱/۱٪	۲۱/۱٪	۲۲/۲٪	۲۲/۲٪	۳۰/۰٪
notable work	۵۳	۱/۹٪	۱/۹٪	۱/۹٪	۱/۹٪	۱/۹٪	۳/۸٪
part of	۳۲	۳/۱٪	۶/۲٪	۱۵/۶٪	۰٪	۹/۴٪	۱۵/۶٪
performer	۳۲	۹/۴٪	۳/۱٪	۳/۱٪	۳/۱٪	۳/۱٪	۱۲/۵٪
has part	۳۲	۹/۴٪	۹/۴٪	۱۵/۶٪	۹/۴٪	۹/۴٪	۱۵/۶٪
country of origin	۳۱	۰٪	۰٪	۰٪	۰٪	۰٪	۰٪
member of	۳۰	۵۳/۳٪	۳۳/۳٪	۳۳/۳٪	۲۳/۳٪	۲۳/۳٪	۶۳/۳٪

دو نکته:

- رابطه‌ی contains معکوس رابطه‌ی located in است. مدل زبانی در v1 هرگز جهت معکوس را نمی‌داد و بازخوانی آن **صفر** بود. لایه‌ی قاعده آن را به ۳۳/۹٪ رساند.
- رابطه‌ی country of origin در همه‌ی نسخه‌ها **صفر** ماند. مدل به‌جای آن معمولاً country را برمی‌گرداند. این یک خطای سیستماتیک در تفکیک دو برچسب نزدیک است و با قاعده‌ی نمادین حل نمی‌شود.

۷.۳ سهم لایه‌ی بستر قاعده‌محور


قاعده	حقیقت تولیدشده در v3	حقیقت تولیدشده در v6
R1 معکوس	۱۵۳	۲۲۸
R2 تراگذاری	۱۰۴	۲۰۳
R3 زنجیره	۱۳	۵۸
جمع	۲۷۰	۴۸۹

در ۷۳، از ۲۷۰ حقیقت استنتاجی ۷۶ مورد در پاسخ طلایی وجود دارد (دقت ۲۸/۱٪). این دقت از دقت مدل زبانی پایین‌تر است، پس لایه‌ی قاعده بازخوانی را می‌خرد و بخشی از دقت را می‌فروشد. چون F1 کل بالا رفت، این معاوضه در هر شش نسخه به سود ما بود.

نکته‌ی مهم طراحی: هر حقیقت استنتاجی شاهد مقدمه‌های خود را به ارث می‌برد. پس قانون «هر یال باید شاهد داشته باشد» در کل سامانه نقض نمی‌شود. یک تست خودکار این را بررسی می‌کند.

۷.۴ نمونه‌ی گراف تولیدشده (سند انگلیسی)

گراف زیر خروجی خام سامانه (نسخه ۷۶) روی سند redocred_dev_0002 است. این سند هر شش نوع موجودیت را دارد. گراف بدون ویرایش دستی آورده شده تا خطا هم دیده شود: یال --located in or next to body of water-- Islington Academy London --to body of water--> London. این دقیقاً همان نوع خطایی است که در بخش ۸/۳ شمارش شد.



۷.۵ همان پایگاه داده و همان رابط وب، برای گراف انگلیسی

کل خروجی ۵۰۰ سند در همان Neo4j و با همان بارگذار فاز ۱ بار شد. تنها تغییر، فلگ --ontology بود:

```
python -m src.load_neo4j data/benchmark/triplets_full.jsonl --ontology configs/ontology_redocr
```


نتیجه‌ی بارگذاری:

مقدار	شاخص
۱۲,۴۳۷ از ۱۲,۴۵۳	رابطه‌ی بارگذاری شده
۵,۹۴۸	گره انگلیسی
۱۲,۳۹۶	یال (بدون یال شاهد)
۹۷	نوع یال متمایز
۳۸	گره شهرداری در همان پایگاه داده


توزیع گره انگلیسی: ۲۱ NUM · ۶۷۲ TIME · ۱,۱۶۸ ORG · ۱,۲۲۳ MISC · ۱,۲۲۸ PER · ۱,۶۳۶ LOC.

۱۶ رابطه بارگذاری نشد. همه از لایه‌ی بستر قاعده‌محور آمدند و ترکیب نوع آن‌ها بیرون ۶۵۴ ترکیب مجاز بود؛ برای نمونه MISC --part of--> NUM. یعنی فیلتر هستان‌شناسی **حقیقت‌های استنتاجی را هم بازرسی می‌کند**، نه فقط خروجی مدل زبانی. قاعده‌ی نمادین اجازه ندارد چیزی وارد گراف کند که هستان‌شناسی آن را مجاز نمی‌داند.

گراف انگلیسی در رابط وب پروژه:



متن شاهد انگلیسی – کلیک روی گره Mess of Blues:



هر رابطه، جمله‌ی منبع خود را نشان می‌دهد. برای نمونه PUBLICATION_DATE 2008 به جمله‌ی «It was released in 2008 less than two weeks after his death» وصل است. پس قانون شاهد در زبان دوم هم برقرار است، بدون یک خط کد تازه.

رابط وب یک فیلتر سند گرفت (<doc=<id?)، چون پایگاه داده اکنون دو گراف را با هم نگه می دارد و کشیدن همزمان همه ی گره ها خوانا نیست.

یکتاسازی موجودیت در مقیاس ۵۰۰ سند. بارگذار، گره ها را با کلید پایدار نوع: نام ادغام می کند. نتیجه:

شاخص	مقدار
جفت (موجودیت، سند) در خروجی	۷,۲۹۸
گره یکتا پس از ادغام	۵,۹۴۸
تکرار حذف شده	۱,۳۵۰
گره ای که در بیش از یک سند آمده	۴۵۸ (۷,۷%)

پرتکرارترین: LOC:American در ۵۸ سند، LOC:France در ۲۲ سند. این همان ادعای بخش ۵/۵/۵ است که حالا در مقیاس واقعی دیده می شود.

ولی یک ضعف واقعی هم هست. کلید، شکل ظاهری دقیق است. پس U.S و United States، the United States. سه گره جدا می سازند، در حالی که یک کشورند. سامانه ذکرهای هم مرجع را درون یک سند یکی می کند، ولی نام های مترادف را بین سندها یکی نمی کند. برای دیتاست شهرداری این مشکل با کلیدگذاری بر پایه ی کد ثابت بودجه حل شده بود، ولی آن راه حل دامنه محور است و به اسناد عمومی تعمیم نمی یابد. راه درست، یک مرحله ی پیوند موجودیت به یک پایگاه دانش مانند Wikidata است که در بخش ۱۱ به عنوان کار آینده آمده.

همچنین ۱۲ سند از ۵۰۰ هیچ رابطه ای ندادند و در گراف نیامدند.

۷.۶ اجرای کامل روی هر ۵۰۰ سند بخش Dev

جدول های بالا روی زیرمجموعه ی ۵۰ سند است. برای اینکه عدد به یک نمونه ی کوچک وابسته نباشد، سامانه روی کل ۵۰۰ سند بخش Dev اجرا شد: ۱۷,۲۸۴ سه تایی طلایی، ۹۵ رابطه ی متمایز، ۱,۰۰۰ فراخوانی مدل زبانی در دو گذر.

نسخه	سه تایی خروجی	Precision	Recall	F1	Ign F1
گذر A – پرامپت جامع، بدون مثال	۶,۱۷۶	۳۶/۸۴	۱۳/۱۶	۱۹/۳۹	۱۹/۹۳
گذر B – همان پرامپت، با دو مثال	۵,۱۰۹	۴۴/۶۳	۱۳/۱۹	۲۰/۳۶	۲۰/۵۳
اجماع A+B + لایه ی بستر	۱۱,۷۸۷	۳۵/۳۲	۲۴/۰۹	۲۸/۶۴	۲۸/۲۳

هر سه یافته ی زیرمجموعه، در مقیاس ده برابر تکرار شد:

یافته	روی ۵۰ سند	روی ۵۰۰ سند
رشد دقت با مثال در پرامپت	۳۶/۴۵ ← ۴۵/۱۱ (۲۴٪+)	۳۶/۸۴ ← ۴۴/۶۳ (۲۱٪+)
رشد بازخوانی با اجماع و قاعده	۱۲/۱۰ ← ۲۶/۹۸	۱۳/۱۹ ← ۲۴/۰۹
F1 نهایی	۲۹/۲۰ (اجماع دو گذر)	۲۸/۶۴ (اجماع دو گذر)

اختلاف F1 بین دو مقیاس ۰/۵۶ واحد است. پس عدد زیرمجموعه اتفاقی نبود.

لایه‌ی بستار روی ۵۰۰ سند ۳,۲۵۱ حقیقت استنتاجی ساخت: R1 معکوس ۱,۸۰۷، R2 تراگذاری ۱,۰۷۳، R3 زنجیره ۳۷۱.

بازخوانی به تفکیک رابطه، روی هر ۵۰۰ سند:

رابطه	تعداد طلایی	بازخوانی
located in the administrative territorial entity	۳,۸۴۶	۳۵/۹٪
country	۲,۷۳۹	۲۱/۶٪
country of citizenship	۸۲۳	۲۵/۳٪
contains administrative territorial entity	۶۶۲	۴۱/۸٪
notable work	۶۰۴	۳/۸٪
has part	۴۶۹	۱۳/۶٪
part of	۴۴۴	۱۴/۰٪
performer	۳۳۰	۳/۹٪
publication date	۲۹۵	۳۵/۹٪
participant of	۲۸۱	۱۴/۲٪

رابطه‌ی contains بالاترین بازخوانی را دارد (۴۱/۸٪)، در حالی که مدل زبانی به‌تنهایی تقریباً هرگز آن را نمی‌دهد. این کل سهم لایه‌ی قاعده‌ی نمادین است.

۷.۷ مقایسه با کارهای منتشرشده

Re-DocRED روی F1	آموزش	سامانه
۸۱/۰۴	نظارت‌شده روی ۳,۰۵۳ سند	KD-DocRE
۷۹/۴۶	نظارت‌شده	ATLOP
۷۷/۸۳	نظارت‌شده	GLiDRE
۹/۷۴	zero-shot	GPT-3.5 + NLI (کار منتشرشده)
۲۳/۵۵	بدون مثال، با هستان‌شناسی مشتق از Train	سامانه‌ی ما (۵۰، ۷3 سند)
۲۹/۶۶	دو مثال از Train + اجماع سه گذر	سامانه‌ی ما (۵۰، ۷6 سند)
۲۸/۶۴	دو مثال از Train + اجماع دو گذر	سامانه‌ی ما (کل ۵۰۰ سند Dev)

نتیجه‌ی مهم: سامانه بدون هیچ مرحله‌ی آموزش گرادیانی و فقط با دو مثال در پرامپت، بیش از سه برابر خط‌مبنای منتشرشده امتیاز گرفت. فاصله با مدل‌های نظارت‌شده زیاد است و این فاصله انتظار درستی است، چون آن مدل‌ها روی ۳ هزار سند برچسب‌خورده آموزش دیده‌اند.

دو هشدار برای خواندن این جدول. نخست، سطر GPT-3.5 واقعاً zero-shot است ولی سطرهای ما نیستند؛ مقایسه‌ی مستقیم به سود ما است. سطر منصفانه برای مقایسه‌ی zero-shot، نسخه‌ی v1 با $F1 = ۱۶/۸۸$ است که آن هم هستان‌شناسی مشتق از Train دارد. دوم، اعداد نظارت‌شده روی بخش Test گزارش شده و عدد ما روی Dev. **هشدار مقایسه:** اعداد مدل‌های نظارت‌شده روی کل بخش Test گزارش شده و عدد ما روی زیرمجموعه‌ی Dev. پس این مقایسه، مقایسه‌ی مرتبه‌ی بزرگی است، نه مقایسه‌ی نقطه‌به‌نقطه.

۷.۸ مرحله‌ی سوم – پیکره‌ی کامل DocRED

پیکربندی در این مرحله **قفل** شد: همان دو پرامپت، همان دو مثال، همان هستان‌شناسی و همان سه قاعده‌ی مرحله‌ی قبل، بدون هیچ تنظیم تازه‌ای. ترتیب اجرا: بخش Dev (۹۹۸ سند)، بخش Test (۱,۰۰۰ سند DocRED به‌اضافه‌ی ۵۰۰ سند Re-DocRED با برچسب بازبینی‌شده)، بخش Train برچسب‌خورده (۳,۰۵۳ سند)، و در پایان بخش نظارت‌ازدور (۱۰۱,۸۷۳ سند).

۷.۸.۱ بخش Dev کامل، ۹۹۸ سند، برچسب‌های اصلی ۱۲,۲۷۵ DocRED. سه‌تایی طلایی، ۹۶ رابطه.

نسخه	سه‌تایی خروجی	Precision	Recall	F1	Ign F1
گذر A – بدون مثال	۱۲,۰۱۹	۱۹/۶۹	۱۹/۲۸	۱۹/۴۹	۱۹/۷۸
گذر B – دو مثال	۹,۷۹۶	۲۳/۲۴	۱۸/۵۵	۲۰/۶۳	۲۰/۵۶
اجماع A+B + لایه‌ی بستار	۲۰,۹۰۳	۱۶/۹۷	۲۸/۹۰	۲۱/۳۸	۲۰/۱۱


الگوی مرحله‌ی قبل تکرار شد: مثال دقت را می‌خرد (۱۹/۶۹ ← ۲۳/۲۴)، اجماع و قاعده بازخوانی را (۱۸/۵۵ ← ۲۸/۹۰). ولی سطح دقت به‌طور کلی پایین‌تر از مرحله‌ی قبل است، و علتش مدل نیست.

۷.۸.۲ همان پیش‌بینی، دو مجموعه برچسب. ۴۹۸ سند از این ۹۹۸ سند، همان سندهای بخش Dev مرحله‌ی قبل‌اند (تطبیق با عنوان). پس می‌شود یک مجموعه پیش‌بینی ثابت را یک بار با برچسب‌های اصلی DocRED و یک بار با برچسب‌های بازبینی‌شده‌ی Re-DocRED سنجید:

برچسب طلایی	سه‌تایی طلایی	Precision	Recall	F1	Ign F1
اصلی DocRED	۶,۱۴۱	۱۶,۷۹	۲۸,۱۴	۲۱,۰۳	۱۹,۹۱
Re-DocRED بازبینی‌شده	۱۷,۱۸۳	۳۵,۵۶	۲۱,۲۹	۲۶,۶۴	۲۶,۰۰

برچسب‌های بازبینی‌شده ۲/۸ برابر بیشترند و دقت اندازه‌گیری‌شده‌ی همان پیش‌بینی‌ها دو برابر می‌شود. یعنی نیمی از «مثبت‌های کاذب» روی برچسب اصلی، رابطه‌هایی هستند که در متن وجود دارند و فقط برچسب نخورده‌اند. این عدد، همان ادعای مقاله‌ی Re-DocRED است که اینجا با سامانه‌ی ما مستقیماً اندازه‌گیری شد. نتیجه‌ی عملی برای خواندن جدول‌های این گزارش: هر عدد دقت روی برچسب اصلی DocRED یک **کران پایین** است.

۷.۸.۳ گراف در مقیاس تازه. خروجی ۹۹۸ سند با بارگذار دسته‌ای در همان Neo4j بار شد: ۲۳,۹۲۷ رابطه در ۱۵ ثانیه. پایگاه اکنون ۱۱,۹۴۳ گره‌ی موجودیت، ۲۸,۷۸۳ یال و ۳۶,۴۰۲ گره‌ی شاهد دارد. کشیدن همه‌ی این‌ها با هم معنا ندارد، پس رابط وب یک جست‌وجوی موجودیت گرفت: نام را می‌نویسید و همسایگی آن با شاهد هر یال می‌آید. نمونه‌ی زیر همسایگی Tehran است؛ پنل سمت چپ جمله‌ی منبع هر رابطه را نشان می‌دهد و سرب‌رگ، اندازه‌ی کل پایگاه را.



۷.۸.۴ بخش‌های باقی‌مانده. اجرای بخش Test، بخش Train برچسب‌خورده و بخش نظارت‌ازدور با همین پیکربندی قفل‌شده در جریان است؛ اجرا ازسرگیری‌پذیر است و نتیجه‌ی هر بخش با تکمیلش به همین بخش اضافه می‌شود. ۳۲۶ سند نخست بخش Test پیش از توقف موقتِ سرویس مدل زبانی استخراج شده و کش شده‌اند.

۸. تحلیل خطا

۸.۱ کار مؤثر فیلتر هستان‌شناسی. در اجرای v2، مدل زبانی ۹۴۸ سه‌تایی برگرداند. فیلتر نوع ۱۹۲ مورد (۲۰/۳٪) را رد کرد. پرتکرارترین موارد:

سه‌تایی ردشده	تعداد	ایراد
PER --performer--> MISC	۱۶	جهت برعکس است. درست آن PER --performer--> MISC است.
PER --end time--> TIME	۱۳	این ترکیب نوع در هستان‌شناسی وجود ندارد.
PER --location--> LOC	۹	برای شخص، رابطه‌ی location تعریف نشده است.
PER --author--> MISC	۸	جهت برعکس است.

۸.۲ کم‌گویی، علت اصلی بازخوانی پایین. هر سند به‌طور میانگین ۳۷/۴ رابطه‌ی طلایی دارد. مدل در نسخه‌ی v1 تنها ۹/۳ رابطه برمی‌گرداند؛ این عدد در v3 به ۱۹/۷ و در v6 به ۳۰/۶ رسید. الگو روشن است: مدل جمله‌های صریح را می‌بیند و از کنار حقیقت‌هایی که باید از زنجیره‌ی هم‌مرجعی یا استنتاج بیرون کشیده شوند رد می‌شود. اجماع چند گذر و لایه‌ی قاعده این شکاف را باریک کردند، اما آن را نبستند.

۸.۳ نوع خطای مثبت کاذب. از ۶۴۹ مثبت کاذب نسخه v3:

نوع خطا	تعداد	سهم
جفت‌موجودیت رابطه دارد، ولی برچسب رابطه اشتباه است	۱۲۸	۱۹/۷٪
جفت‌موجودیت در پاسخ طلایی هیچ رابطه‌ای ندارد	۵۲۱	۸۰/۳٪

یعنی حدود یک‌پنجم خطاها «انتخاب اشتباه یکی از ۹۶ برچسب» است، نه ساختن رابطه از هوا.

۸.۴ خطای نگاشت نام. در ۹۰، ۷۶ سطر از ۱,۶۴۵ سطر (۵/۵٪) به موجودیت طلایی نگاشت نشد، چون مدل نام را دقیقاً از فهرست کپی نکرد. این نرخ در v3 برابر ۳/۶٪ بود. اجماع چند گذر، خطای نگاشت را هم جمع می‌کند.

۸.۵ ممیزی مستقل ارزیاب

پس از تکمیل نتایج، کد ارزیابی و تست‌ها به یک مدل زبانی دیگر (gpt-5.6) داده شد تا **علیه** ادعاهای این گزارش استدلال کند. چهار ایراد از یازده ایراد گزارش‌شده معتبر بود و هر چهار مورد اصلاح شد:

ایراد	وضعیت	نتیجه
کلید Ign F1 در بخش Train از اولین ذکر ساخته می‌شد، ولی در Dev از ذکر الفبایی نخست. دو کلید ناهمخوان.	درست بود، اصلاح شد	همه‌ی شکل‌های ظاهری وارد کلید شدند. تعداد کلید Train از ۷۷,۷۰۰ به ۱۱۰,۲۶۵ رسید. Ign F1 حدود ۰/۳ واحد جابه‌جا شد.
تطبیق نام، وقتی نوع نمی‌خواند، باز هم قبول می‌کرد و می‌توانست عدد را متورم کند.	درست بود، اندازه‌گیری شد	حالت strict-types-- افزوده شد. اختلاف ۰/۰۲ واحد بود (بخش ۶/۶). ادعا سالم ماند.
گزارش خود را «zero-shot» می‌نامید، در حالی که هستان‌شناسی و مثال‌ها از Train می‌آیند.	درست بود، اصلاح شد	واژه‌ها بازنویسی شد و بخش ۶/۴ نوشته شد.
سه تست ادعای نامشان را ثابت نمی‌کردند.	درست بود، اصلاح شد	تست قاعده‌ها حالا تعداد فعال‌شدن را می‌شمارد، تست Ign حذف از هر دو استخر را می‌سنجد، و یک تست تازه برای برخورد نام‌های یکسان افزوده شد.

یک ایراد **رد شد**: ادعای نشت پاسخ طلایی از لایه‌ی بستار. آن لایه فقط پیش‌بینی‌ها را می‌خواند و هرگز فایل طلایی را باز نمی‌کند.

نتیجه: هیچ‌کدام از اعداد F1 تغییر نکرد. تنها Ign F1 حدود ۰/۳ واحد جابه‌جا شد و دو ادعای واژگانی تصحیح شد.

۹. محدودیت‌ها

1. عددهای اصلی روی بخش Dev گزارش شده‌اند: ۵۰۰ سند با برچسب بازبینی‌شده (بخش ۷/۶) و ۹۹۸ سند با برچسب اصلی (بخش ۷/۸). اجرای بخش Test با پیکربندی قفل‌شده در جریان است و عدد آن پس از تکمیل به بخش ۷/۸ اضافه می‌شود.
2. برچسب‌های اصلی DocRED ناقص‌اند و دقت را حدود دو برابر کمتر از واقع نشان می‌دهند (بخش ۷/۸/۲). برچسب بخش نظارت‌ازدور از این هم نویزی‌تر است؛ عدد آن بخش «توافق» است، نه دقت.
3. نگاشت پاسخ بر پایه‌ی نام موجودیت است، نه اندیس. سقف آن حدود ۹۹/۷ است (بخش ۶/۳ و ۶/۶).
4. پرامپت‌ها روی همان بخش Dev تنظیم شدند که عدد از آن گزارش می‌شود. یک اجرای واحد روی بخش Test با پیکربندی قفل‌شده، عدد بی‌طرفانه‌تری می‌دهد (بخش ۶/۵).
5. لایه‌ی قاعده فقط سه قاعده دارد. قاعده‌های بیشتر از روی بخش Train قابل استخراج خودکار هستند.
6. سامانه از یک مدل زبانی تجاری استفاده می‌کند. نتیجه به نسخه‌ی مدل وابسته است.

۱۰. فصل آخر – مطالعه‌ی موردی ایرانی: گراف دانش اسناد شهرداری

این فصل همان مدل را، بدون تغییر معماری، روی داده‌ی فارسی واقعی اجرا می‌کند. هدف این فصل نشان دادن انتقال‌پذیری سامانه به یک دامنه و زبان دیگر است.

۱۰.۱ دیتاست

اسناد واقع‌نمای شهرداری تهران به زبان فارسی. دیتاست به‌صورت عمدی به‌هم‌پیوسته طراحی شده است: یک موجودیت (مثلاً «پروژه‌ی بهسازی پل صدر» یا یک ردیف بودجه) در چند سند مختلف با نقش‌های متفاوت ظاهر می‌شود.

ویژگی	مقدار
تعداد سند منبع	۷
قالب ورودی	TXT، DOCX، PDF، PNG/JPG (تصویر با OCR)
نوع سند	قرارداد، گزارش پروژه، صورت‌جلسه‌ی نظارت، گزارش شکایت، تخصیص بودجه
حجم متن خام	۸۱۱ کلمه
قطعه (chunk)	۷
سه‌تایی خام با شاهد	۳۹
گره یکتا	۳۸
یال یکتا پس از MERGE	۳۲
نوع موجودیت	۶
نوع رابطه	۵

هستان‌شناسی: موجودیت‌ها = {پروژه، پیمانکار، مکان، مسئول، بودجه، شکایت}. رابطه‌ها = {پیمانکار→مجری→پروژه، پروژه→واقع‌در→مکان، مسئول→ناظر→پروژه، بودجه→تأمین‌مالی→پروژه، شکایت→درباره‌ی→پروژه/مکان}.

توزیع موجودیت: مکان ۱۲، شکایت ۶، پروژه ۵، پیمانکار ۵، ناظر ۵، بودجه ۵ – جمع ۳۸.


توزیع رابطه (خام): واقع‌در ۱۱، تأمین‌مالی ۱۰، ناظر ۷، شکایت‌درباره‌ی ۶، مجری ۵ – جمع ۳۹، که پس از MERGE به ۳۲ یال یکتا رسید.

۱۰.۲ نتیجه


دقت: پس از مقایسه‌ی کامل گراف با متن منبع، تمام رابطه‌های استخراج‌شده مورد تأیید متن بودند (~۱۰۰٪). هیچ رابطه‌ی جعلی یا خارج از هستان‌شناسی وارد گراف نشد.

یکتایی موجودیت: با کلیدگذاری بودجه بر پایه‌ی کد ثابت، یک بودجه که در چند سند با نام‌های متفاوت آمده بود به یک گره‌ی واحد نگاشت شد.

نمای گراف دانش تولیدشده:



نمونه‌ی ردیابی – کلیک روی یک گره، رابطه‌ها و جمله‌ی منبع را نشان می‌دهد:



۱۰.۳ چرا دقت اینجا ~۱۰۰٪ است و روی ۳۵٪ Re-DocRED؟

وسوسه‌انگیز است که این تفاوت را به حساب بهتر کار کردن مدل روی فارسی بگذاریم، اما هیچ شاهده‌ی برای چنین ادعایی نداریم. سه توضیح ساده‌تر وجود دارد.

نخست، فضای برچسب اینجا پنج رابطه دارد و آنجا نود و شش تا. وقتی مدل باید از میان پنج گزینه یکی را بردارد، احتمال انتخاب غلط طبیعتاً بسیار کمتر است.

دوم، و مهم‌تر از همه، ارزیابی اینجا دستی بود نه مبتنی بر برچسب طلایی. ما فقط می‌توانیم بگوییم هرچه استخراج شد درست بود؛ اینکه چه چیزهایی از قلم افتاد را اصلاً نمی‌دانیم. به بیان دقیق‌تر، آنچه اندازه گرفتیم دقت بود و نه بازخوانی، و عدد ۱۰۰٪ فقط نیمی از تصویر است.

سوم، اسناد شهرداری کوتاه و صریح‌اند و رابطه‌ی بین‌جمله‌ای در آن‌ها کم است، حال آنکه در Re-DocRED بیش از نیمی از رابطه‌ها (۵/۵۳٪) بین دو موجودیتی برقرارند که هرگز در یک جمله کنار هم نیامده‌اند.

همین مقایسه توضیح می‌دهد که چرا رفتن سراغ یک بنچمارک استاندارد ضروری بود: وقتی برچسب طلایی در کار نباشد، عدد دقت بیش از آنکه اطلاع بدهد، گمراه می‌کند.

۱۰.۴ جدول مقایسه‌ی دو دیتاست

شاخص	شهرداری (مطالعه موردی)	Re-DocRED (مرحله‌ی ۱ و ۲)	DocRED کامل (مرحله‌ی ۳)
تعداد سند	۷	۴,۰۵۳	۱۰۶,۹۲۴
تعداد واژه	۸۱۱	۸۰۴,۱۷۲	۲۱,۳۳۰,۱۹۰
تعداد موجودیت	۳۸	۷۸,۸۲۲	۲,۰۶۴,۰۴۴
تعداد سه‌تایی	۳۹	۱۲۰,۶۶۴	۱,۵۵۶,۰۹۳
نوع رابطه	۵	۹۶	۹۶
برچسب طلایی	ندارد	انسانی، بازبینی‌شده	انسانی (۴,۰۵۱ سند) + نظارت‌ازدور (۱۰۱,۸۷۳ سند)
رابطه‌ی بین‌جمله‌ای	کم	۵۳/۵٪	۵۷/۶٪
زبان	فارسی	انگلیسی	انگلیسی

۱۰.۵ نتیجه‌ی فصل

سامانه بدون آنکه معماری‌اش دست بخورد روی دو زبان، دو دامنه و دو هستان‌شناسی کار کرد که تعداد رابطه‌هایشان ۱۹ برابر با هم فرق دارد. تنها چیزی که میان این دو اجرا عوض شد یک فایل JSON بود. اگر بخواهیم یک درس از این فصل بیرون بکشیم، همین است که جدا نگه داشتن هستان‌شناسی از کد – تصمیمی که در آغاز صرفاً تمیزکاری به نظر می‌رسید – چیزی است که انتقال‌پذیری را ممکن کرد.

۱۱. نتیجه‌گیری و کار آینده

نتیجه‌گیری. آنچه از این کار می‌ماند این است که مدل زبانی به‌تنهایی برای ساخت گراف دانش کافی نیست، ولی وقتی کنار یک هستان‌شناسی مقید، الزام شاهد و یک لایه‌ی استنتاج نمادین بنشیند، می‌توان از متن غیرساختاریافته گرافی ساخت که هم دقیق باشد و هم بشود هر ادعایش را تا جمله‌ی منبع دنبال کرد – آن هم بدون هیچ داده‌ی آموزشی برچسب‌خورده‌ی دامنه‌ای.

روی بنچمارک استاندارد Re-DocRED، سامانه **بیش از سه برابر** خط‌مبنای منتشرشده امتیاز گرفت: ۲۹/۶۶ روی زیرمجموعه و ۲۸/۶۴ روی کل ۵۰۰ سند Dev، در برابر ۹/۷۴. این عدد از یک سامانه‌ی بدون آموزش گرادیانی می‌آید، نه از یک سامانه‌ی بی‌نظارت. چهار یافته‌ی کلیدی، که هر چهار مورد در مقیاس ده برابر هم تکرار شدند:

1. فیلتر هستان‌شناسی واقعاً توهم را می‌گیرد – ۲۰/۳٪ از خروجی مدل رد شد و پرتکرارترین ایراد، معکوس بودن جهت رابطه بود.
2. مثال کاری در پرامپت، دقت را می‌خرد، نه بازخوانی را – دقت ۲۴٪ رشد نسبی کرد و نرخ رد شدن از ۲۰/۳٪ به ۱۸/۷٪ رسید.
3. گلوگاه، بازخوانی است نه دقت – مدل زبانی کم‌گو است. لایه‌ی قاعده‌ی نمادین و اجماع چند گذر با هم بازخوانی را از ۱۰/۵۵ به ۲۶/۹۸ رساندند.
4. $Ign F1$ نزدیک یا بالاتر از $F1$ است – یعنی امتیاز از حفظ‌کردن دانش پیش‌آموخته‌ی مدل نمی‌آید، بلکه از خواندن متن سند می‌آید.

کار آینده. ۱. بازیابی مثال مشابه برای هر سند (retrieval-augmented few-shot) به‌جای مثال ثابت. ۲. استخراج خودکار قاعده‌های بیشتر از بخش Train، به‌جای سه قاعده‌ی دست‌نویس. ۳. رأی‌گیری وزن‌دار در اجماع، به‌جای اجماع ساده، برای بازگرداندن بخشی از دقتِ ازدست‌رفته. ۴. پیوند موجودیت به یک پایگاه دانش (مانند Wikidata)، تا U.S و United States به یک گره برسند. ۵. نگاشت بر پایه‌ی اندیس به‌جای نام، برای برداشتن سقف ۹۹/۷. ۶. افزودن لایه‌ی پرسش‌وپاسخ طبیعی روی گراف (Graph-QA).

```
# ۱) Train آماده‌سازی داده و هستان‌شناسی خودکار از بخش ۱)
python -m src.redocred prepare --split dev --limit 50

# ۲) Train ساخت مثال‌های پرامپت از بخش ۲)
python -m src.redocred fewshot --n 2

# ۳) پرامپت جامع، بدون مثال – A گذر
python -m src.extract data/benchmark/chunks_dev.jsonl \
    --out data/benchmark/triplets_dev_v2.jsonl \
    --ontology configs/ontology_redocred.json

# ۴) همان پرامپت، با دو مثال کاری – B گذر
python -m src.extract data/benchmark/chunks_dev.jsonl \
    --out data/benchmark/triplets_dev_v4.jsonl \
    --ontology configs/ontology_redocred.json \
    --fewshot configs/fewshot_redocred.json

# ۵) اجماع گذرها + لایه‌ی بستر قاعده‌محور
cat data/benchmark/triplets_dev_v1.jsonl \
    data/benchmark/triplets_dev_v2.jsonl \
    data/benchmark/triplets_dev_v4.jsonl > data/benchmark/_union.jsonl
python -m src.redocred closure data/benchmark/_union.jsonl \
    --out data/benchmark/triplets_dev_v6.jsonl

# ۶) ارزیابی
python -m src.redocred eval data/benchmark/triplets_dev_v6.jsonl \
    --gold data/benchmark/gold_dev50.jsonl \
    --report data/benchmark/eval_report_v6.json

# ۷) گزارش PDF نمودار گراف یک سند و
python -m src.redocred graph data/benchmark/triplets_dev_v6.jsonl \
    --doc redocred_dev_0002 --out docs/graph_redocred.md
python -m src.md2pdf docs/FINAL_REPORT.md

# ۸) (Docker نیازمند اجرای) Neo4j بارگذاری گراف انگلیسی در همان
python -m src.load_neo4j data/benchmark/triplets_dev_v6.jsonl \
    --ontology configs/ontology_redocred.json
```

بارگذار Neo4j هم مانند استخراج‌کننده، هستان‌شناسی را از فایل JSON می‌خواند. پس همان پایگاه‌داده و همان رابط وب، گراف انگلیسی را هم نشان می‌دهد. نام رابطه‌ی انگلیسی که فاصله دارد، به نوع یال Cypher تبدیل می‌شود؛ برای نمونه located in the administrative territorial entity به

LOCATED_IN_THE_ADMINISTRATIVE_TERRITORIAL_ENTITY.

یا با یک فرمان:

```
.\rebuild.ps1 -Benchmark -Pdf # اجرای بنچمارک روی ۵۰ سند و ساخت
.\rebuild.ps1 -Full # اجرای کامل روی هر ۵۰۰ سند بخش
.\rebuild.ps1 -DocRED -Workers 48 # ۴۸ درخواست همزمان DocRED: پیکره‌ی کامل
.\rebuild.ps1 # ساخت گراف شهرداری در Neo4j
```

اجرای پیکره‌ی کامل، مرحله به مرحله:

```
# داده‌ی DocRED از HuggingFace (۱۰۶ مگابایت Parquet، چهار فایل)
python -m src.docred prepare # chunks_*.jsonl و gold_*.jsonl → چهار بخش
python -m src.docred stats # stats.json → آمار پیکره

# ثبت می‌شود usage.json. استخراج همزمان و ازسرگیری‌پذیر؛ توکن مصرفی در
python -m src.extract data/benchmark/docred/chunks_validation.jsonl \
    --out data/benchmark/docred/triplets_validation_a.jsonl \
    --ontology configs/ontology_redocred.json --workers 48

# ارزیابی یک مجموعه پیش‌بینی با هر فایل طلایی
python -m src.redocred eval data/benchmark/docred/triplets_validation.jsonl \
    --gold data/benchmark/docred/gold_validation.jsonl \
    --report data/benchmark/docred/eval_report_validation.json

# بارگذاری دسته‌ای در Neo4j
python -m src.load_neo4j data/benchmark/docred/triplets_validation.jsonl \
    --ontology configs/ontology_redocred.json
```

هر دو گذر ازسرگیری‌پذیر هستند. اگر اجرا نیمه‌کاره بماند، همان فرمان کار را از همان‌جا ادامه می‌دهد: خروجی در فایل . part نوشته می‌شود و اجرای بعدی آن را هم می‌خواند.

تست‌های آفلاین (بدون شبکه و بدون مدل زبانی):

```
python -m tests.test_extract # تست هستان‌شناسی و اعتبارسنجی ۶
python -m tests.test_redocred # تست ارزیاب و لایه‌ی قاعده ۶
```

خروجی هر دو: all passed.

پیوست ب – فایل‌های تولیدشده

فایل	محتوا
src/ingest.py	ورود سند، OCR تصویر، نرمال‌سازی، قطعه‌بندی
src/extract.py	استخراج با مدل زبانی، اعتبارسنجی، فیلتر هستان‌شناسی، few-shot
src/load_neo4j.py	بارگذاری idempotent در Neo4j
src/app.py + web/index.html	رابط وب نمایش گراف
src/redocred.py	آماده‌سازی بنچمارک، ساخت مثال، بستار قاعده‌محور، ارزیاب، نمودار
src/md2pdf.py	تبدیل گزارش فارسی به PDF با Chromium
rebuild.ps1	اجرای کل خط لوله با یک فرمان
configs/ontology_redocred.json	۹۶ رابطه و ۶۵۴ ترکیب مجاز
configs/fewshot_redocred.json	مثال‌های پرامپت، برگرفته از بخش Train
data/benchmark/triplets_dev_v1..v6.jsonl	خروجی هر شش نسخه روی زیرمجموعه
data/benchmark/eval_report_v1..v6.json	گزارش عددی هر شش نسخه، با بازخوانی به تفکیک رابطه
data/benchmark/triplets_full.jsonl	خروجی اجرای کامل روی ۵۰۰ سند
data/benchmark/eval_report_full.json	گزارش عددی اجرای کامل
tests/test_extract.py، tests/test_redocred.py	۱۲ تست آفلاین
docs/DATASET_PROPOSAL.md	سند فاز ۱ برای استاد
docs/PHASE2_RESULTS.md	گزارش تفصیلی فاز ۲
docs/graph_redocred.md	نمودار گراف یک سند انگلیسی
src/docred.py	خواندن چهار بخش Parquet پیکره‌ی DocRED، ساخت chunk و gold، آمار پیکره
data/benchmark/docred/stats.json، stats_detail.json	آمار محاسبه‌شده‌ی پیکره‌ی کامل
data/benchmark/docred/eval_report_validation*.json	گزارش عددی بخش Dev کامل، هر گذر، و مقایسه‌ی دو مجموعه برچسب
data/benchmark/docred/*.usage.json	توکن مصرفی و زمان هر گذر، خوانده‌شده از پاسخ سرویس